

中等复杂度二分类的量子机器学习 (VQC)

姓名：郝思粤

学号：__ PB23151779

日期：__ 2025年12月17日

框架： PennyLane

1. 实验目的

- 实现一个中等复杂度的二分类量子机器学习模型 (VQC)，并在图像类数据上完成训练与测试。
- 理解“经典数据 → 量子态嵌入 → 参数化量子线路 → 测量输出 → 经典优化训练”的完整流程。
- 观察训练曲线与测试效果，分析模型收敛与泛化情况。

2. 实验原理（简要）

本实验采用变分量子分类器 (VQC)，核心流程如下：

- 数据嵌入 (Embedding)：将经典特征向量映射为量子态

$$|\psi(x)\rangle = U_{\text{embed}}(x)|0\rangle^{\otimes n}$$

- 参数化量子线路 (Ansatz)：引入可训练参数 θ

$$|\phi(x, \theta)\rangle = U(\theta)|\psi(x)\rangle$$

- 测量输出并转为概率：以 Pauli-Z 期望为输出

$$\langle Z \rangle \in [-1, 1], \quad p = \frac{\langle Z \rangle + 1}{2} \in [0, 1]$$

- 损失函数 (交叉熵)：用于二分类训练

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{i=1}^N [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

3. 实验环境

- Python: 3.10.19
- PennyLane: 0.35+
- scikit-learn: 用于数据集与划分
- matplotlib: 用于绘图

依赖安装:

- `pip install pennylane scikit-learn matplotlib`
-

4. 实验任务与数据集

- 任务: 二分类 (0 vs 1)
 - 数据: 使用 sklearn 内置 digits 数据集 (8×8 手写数字)
 - 预处理: 将 8×8 图像降采样为 4×4 (得到 16 维特征)
 - 量子比特数: 4 (因为 $16 = 2^4$, 便于振幅编码)
-

5. 实验过程

5.1 数据集构建与预处理

本实验选用 sklearn 内置的手写数字数据集 (digits), 原始图像大小为 8×8。为了构建中等复杂度的二分类任务, 仅保留数字“0”与“1”两个类别。

在预处理阶段, 首先将像素值归一化到区间 $[0,1]$, 随后将 8×8 图像通过平均池化的方式降采样为 4×4 图像, 并展平成 16 维特征向量。该维度恰好对应 2^4 , 便于后续进行振幅嵌入。

5.2 量子模型设计

模型采用变分量子分类器 (VQC) 结构, 使用 4 个量子比特。经典特征通过振幅嵌入方式映射到量子态中, 使每个样本对应一个 4 比特量子态。

在嵌入后的量子态上, 构建参数化量子线路作为 Ansatz, 采用多层纠缠结构以增强模型的表达能力。量子电路最终通过测量某一量子比特的 Pauli-Z 期望值作为输出, 并映射为二分类概率。

5.3 训练策略

模型训练采用交叉熵损失函数, 并使用 Adam 优化器对量子电路参数进行更新。训练过程中采用小批量 (mini-batch) 方式进行优化, 以提高训练的稳定性。

在每个 epoch 结束后，分别计算训练集与测试集的准确率，同时记录训练损失，用于后续的训练过程分析与可视化。

6. 实验结果

输出如下：


```
Epoch 00 | loss=0.5888 | train_acc=0.874 | test_acc=0.811
Epoch 01 | loss=0.4463 | train_acc=0.956 | test_acc=0.811
Epoch 02 | loss=0.4405 | train_acc=0.904 | test_acc=0.778
Epoch 03 | loss=0.4377 | train_acc=0.922 | test_acc=0.778
Epoch 04 | loss=0.4365 | train_acc=0.915 | test_acc=0.767
Epoch 05 | loss=0.4363 | train_acc=0.915 | test_acc=0.767
Epoch 06 | loss=0.4363 | train_acc=0.915 | test_acc=0.767
Epoch 07 | loss=0.4363 | train_acc=0.915 | test_acc=0.767
Epoch 08 | loss=0.4363 | train_acc=0.915 | test_acc=0.767
Epoch 09 | loss=0.4364 | train_acc=0.919 | test_acc=0.767
Epoch 10 | loss=0.4367 | train_acc=0.907 | test_acc=0.756
Epoch 11 | loss=0.4364 | train_acc=0.915 | test_acc=0.767
Epoch 12 | loss=0.4367 | train_acc=0.915 | test_acc=0.767
Epoch 13 | loss=0.4366 | train_acc=0.919 | test_acc=0.767
Epoch 14 | loss=0.4364 | train_acc=0.915 | test_acc=0.767
Epoch 15 | loss=0.4365 | train_acc=0.915 | test_acc=0.767
Epoch 16 | loss=0.4364 | train_acc=0.915 | test_acc=0.767
Epoch 17 | loss=0.4368 | train_acc=0.922 | test_acc=0.778
Epoch 18 | loss=0.4369 | train_acc=0.911 | test_acc=0.756
Epoch 19 | loss=0.4368 | train_acc=0.922 | test_acc=0.778
Epoch 20 | loss=0.4372 | train_acc=0.922 | test_acc=0.789
Epoch 21 | loss=0.4428 | train_acc=0.915 | test_acc=0.789
Epoch 22 | loss=0.4389 | train_acc=0.922 | test_acc=0.789
Epoch 23 | loss=0.4369 | train_acc=0.911 | test_acc=0.756
Epoch 24 | loss=0.4368 | train_acc=0.911 | test_acc=0.756
Epoch 25 | loss=0.4366 | train_acc=0.915 | test_acc=0.767
Epoch 26 | loss=0.4364 | train_acc=0.915 | test_acc=0.767
Epoch 27 | loss=0.4371 | train_acc=0.922 | test_acc=0.778
Epoch 28 | loss=0.4367 | train_acc=0.922 | test_acc=0.778
Epoch 29 | loss=0.4365 | train_acc=0.919 | test_acc=0.767

训练完成。
最终测试准确率： 0.7666666666666667
```

6.1 训练损失变化

本实验在训练过程中记录了每个 epoch 的交叉熵损失，并绘制了训练损失曲线。

【图：Training Loss Curve (训练损失曲线图)】




从训练损失曲线可以看出，损失值在初始阶段迅速下降，随后逐渐趋于平稳，最终在较低水平附近波动。这表明模型在前几个 epoch 内完成了主要的特征学习，后续训练更多是在细化参数，而未出现明显的震荡或发散现象，训练过程整体较为稳定。

6.2 分类准确率分析

在训练过程中，同时记录了训练集与测试集的分类准确率变化情况，并绘制了准确率曲线。

【图：Accuracy Curve（训练集与测试集准确率曲线图）】



从准确率曲线可以观察到，训练集准确率很快上升并稳定在 0.90 以上，说明模型能够较好地拟合训练数据。而测试集准确率整体维持在 0.75–0.80 区间，且存在一定波动，表明模型在未见数据上的泛化能力有限。

训练集与测试集准确率之间的差距说明模型存在一定程度的过拟合现象，这在样本规模较小、量子线路参数有限的条件下是可以接受的，也反映了当前量子模型在复杂任务上的现实限制。

总体来看，模型成功完成了中等复杂度的二分类任务，并验证了变分量子分类器在图像类数据上的可行性。

7. 实验总结

在本次实验中，我基于 PennyLane 框架实现了一个用于中等复杂度二分类任务的变分量子分类器（VQC），并将其应用于降采样后的手写数字数据（4×4 digits, 0 vs 1）。通过完整的实验流程，我进一步理解了量子机器学习中“经典数据 → 量子态嵌入 → 参数化量子线路 → 测量输出 → 经典优化训练”的基本思想。

从实验结果来看，训练损失在前几个 epoch 内快速下降并趋于稳定，说明模型能够有效学习数据的主要特征结构；训练集准确率较高，而测试集准确率相对较低且存在波动，表明模型在一定程度上出现了过拟合。这一现象与样本规模较小、量子线路规模有限等因素有关，也反映了当前量子模型在复杂任务上的实际限制。

总体而言，本次实验验证了变分量子分类器在图像类二分类任务中的可行性，加深了我对量子-经典混合学习方法的理解。实验结果为后续进一步尝试更复杂的数据集或改进量子线路结构提供了参考和基础。