

实验报告：量子机器学习库

课程名称：量子计算与机器学习

姓名：郝思粤

学号：PB23151779

日期：2025.12.10

一、实验目的

本实验旨在完成对量子机器学习（Quantum Machine Learning, QML）基础框架与核心模型的认识与实践，具体目标包括：

- 理解主流量子机器学习工具链（PennyLane、Qiskit ML、TFQ）的定位与典型用例，掌握其在量子-经典混合学习中的作用。
- 熟悉 PennyLane 框架的安装与配置流程，掌握可微量子电路的构建方法。
- 通过实现一个小型变分量子分类器（VQC），理解数据嵌入、参数化量子线路（Ansatz）、量子测量及经典优化的完整训练流程。
- 初步认识量子机器学习与经典机器学习的区别，为后续更复杂的二分类任务（如 MNIST 子集）打下基础。

二、实验原理

本实验基于“可微量子电路（Differentiable Quantum Circuits）”与“变分量子算法（Variational Quantum Algorithms, VQA）”的核心思想，涉及以下关键原理：

- 数据量子化（Quantum Embedding）
将经典数据映射为量子态，例如通过单比特旋转门实现

$$|\psi(x)\rangle = U_{\text{embed}}(x)|0\rangle$$

使输入样本具有几何意义的量子表示。

- 参数化量子电路（Parameterized Quantum Circuit, PQC）
使用可训练参数

$$\theta$$

的量子门构成量子神经网络：

$$|\phi(x, \theta)\rangle = U(\theta)|\psi(x)\rangle$$

PQC 可通过调整参数逼近分类边界。

- 量子测量与概率输出
模型输出来自测量期望值：

$$\langle Z \rangle = \langle \phi | Z | \phi \rangle$$

再通过变换得到分类概率：

$$p = \frac{\langle Z \rangle + 1}{2}$$

- 经典优化器参与训练
损失函数（如 MSE）：

$$\mathcal{L}(\theta) = \frac{1}{N} \sum_i (p_i - y_i)^2$$

通过 PennyLane 的自动微分机制计算量子电路参数的梯度，并执行更新：

$$\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}(\theta)$$

变分量子分类器（VQC）结合了量子态空间的高维特征表示能力与经典优化的训练效率，是当前量子机器学习应用最广泛的模型之一。

三、实验环境

本实验环境配置如下：

- 操作系统： macOS
- Python 版本： 3.10.19
- 量子机器学习框架： PennyLane（本次实验使用）
- 主要依赖库：
 - PennyLane ≥ 0.35
 - NumPy (pennylane.numpy)
 - Matplotlib（用于训练曲线可视化）

四、实验步骤

Q1、量子机器学习库认识

1.PennyLane调研

本实验最终选择 PennyLane 作为主要实践工具。

定位：

PennyLane 是目前学术界使用最广泛的混合量子-经典机器学习框架，专注于可微量子电路（differentiable quantum circuits）与自动求导机制。

典型用例：

- 变分量子分类器（VQC）
- 量子神经网络（QNN）
- 量子生成模型
- 量子化学基态求解
- 与 PyTorch / TensorFlow 深度学习模型无缝结合

特点：

- 支持量子电路的端到端自动微分
- 可直接与主流深度学习框架连接
- 支持多种后端（如模拟器、IBMQ 等真实量子硬件）
- 社区活跃，文档完善，适合教学与科研

2.PennyLane安装与配置

- 打开虚拟环境，使用 `pip install pennylane` 安装
- 使用如下代码测试是否安装成功：

```
import pennylane as qml

print(qml.__version__)
```

输出如下：

```
0.42.3
```

表明安装成功，版本号为 0.42.3

Q2、小型变分量子分类器

2-1 小型变分量子分类器实验步骤

本实验基于 PennyLane 构建一个最基础的变分量子分类器（VQC），通过参数化量子电路（PQC）实现一个简单的二分类任务。

Step 1：构造二分类数据集

本实验使用一个最简单的二维数据集，其中每个样本仅包含一个特征值。为便于量子线路学习，我们人为构造两个数值差异明显的数据点，例如：

- 输入样本

$$x_1 = 0.1$$

的类别为

$$y_1 = 0$$

- 输入样本

$$x_2 = 1.0$$

的类别为

$$y_2 = 1$$

目标是训练参数化量子电路，使其输出尽可能接近真实标签。

Step 2：创建量子计算设备

本实验选择单量子比特设备，即只使用一个量子比特进行数据编码与参数化操作。

设备的作用包括：

- 模拟量子态演化
 - 模拟观测结果（期望值）
 - 将量子线路与经典优化器结合用于训练
-

Step 3：设计参数化量子电路（PQC）

参数化量子电路包含以下三大部分：

(1) 数据嵌入（Quantum Embedding）

将经典标量

映射到量子态。

常见做法是使用单量子比特绕某个轴的旋转，将数值转换成 Bloch 球上的一个量子态。
例如：
数据嵌入后的量子态记为：

$$|\psi(x)\rangle = U_{\text{embed}}(x)|0\rangle.$$

其目的：

- 不同的输入

$$x$$

映射成不同的量子态

- 为量子模型提供可学习的几何结构（量子态空间）

(2) 可训练的参数化量子线路 (Ansatz)

接着对嵌入后的量子态施加含参数的量子操作。
例如，可以使用 3 个旋转参数：

$$\theta = (\theta_1, \theta_2, \theta_3)$$

并作用于量子比特：

$$|\phi(x, \theta)\rangle = U_{\text{ansatz}}(\theta)|\psi(x)\rangle.$$

Ansatz 的作用：

- 决定模型的表达能力
- 通过训练更新参数，使模型拟合分类任务

(3) 量子测量

量子电路最终输出为某个算符的期望值，例如 Pauli-Z 的期望：

$$\langle Z \rangle = \langle \phi(x, \theta) | Z | \phi(x, \theta) \rangle.$$

其输出范围为

$$[-1, 1]$$

，不能直接作为分类概率使用，需要进一步规范化。

Step 4：构造分类概率与损失函数

将测量输出映射到概率区间

$$[0, 1]$$

:

$$p(x) = \frac{\langle Z \rangle + 1}{2}.$$

训练目标：使模型输出

$$p(x_i)$$

尽可能接近真实标签

$$y_i \in \{0, 1\}$$

。

损失函数使用均方误差（MSE）：

$$\mathcal{L}(\theta) = \frac{1}{N} \sum_{i=1}^N (p(x_i; \theta) - y_i)^2.$$

这是经典的监督学习目标。

Step 5：参数初始化与经典优化器

- 参数向量

$$\theta$$

会初始化为随机值

- 使用经典优化器（如梯度下降）迭代更新

$$\theta$$

- 每次迭代通过“量子前向传播 + 量子自动微分”计算梯度

更新规则为：

$$\theta^{(t+1)} = \theta^{(t)} - \eta \nabla_{\theta} \mathcal{L}(\theta^{(t)}),$$

其中：

-

$$\eta$$

为学习率（例如 0.3）

- t
表示迭代轮数（epoch）

Step 6：训练模型并记录损失变化

每一轮训练过程包括：

1. 用当前

$$\theta$$

对每个样本进行一次量子前向计算

2. 计算训练损失

$$\mathcal{L}(\theta)$$

3. 使用优化器更新参数
4. 将当前损失加入列表，以便后续绘图

如果损失逐渐减小，表示模型成功学习到了分类边界。

Step 7：训练曲线可视化

训练结束后，将存储的损失值绘制成曲线。

横轴：epoch（训练轮数）

纵轴：

$$\mathcal{L}(\theta)$$

（损失值）

若曲线随训练轮数整体下降，即：

$$\mathcal{L}(\theta^{(t+1)}) < \mathcal{L}(\theta^{(t)}),$$

说明量子分类器成功拟合了数据。

Step 8：结果分析与讨论

可以从以下角度分析训练结果：

- 参数化量子线路是否足够表达分类边界
- 损失收敛速度是否平稳
- 数据嵌入方式（如单旋转）是否适合当前任务
- 量子模型是否成功将两个不同的输入映射到不同的量子区域

最终，我们验证了一个变分量子分类器（VQC）如何通过参数更新完成二分类任务。

该步骤核心代码：

```
import pennylane as qml

from pennylane import numpy as np

import matplotlib.pyplot as plt


# 1. 创建量子设备：1 个量子比特

dev = qml.device("default.qubit", wires=1)


# 2. 构造简单二分类数据集

# X: 输入特征, Y: 标签

X = np.array([[0.1], [1.0]]) # 形状为 (2, 1)

Y = np.array([0, 1]) # 标签 0 和 1


# 3. 定义参数化量子电路 (PQC)

@qml.qnode(dev)

def circuit(x, theta):

    """

    x : 标量输入 (这里是一维)
```


theta : 长度为 3 的可训练参数向量

.....

数据嵌入

qml.RX(x, wires=0)

参数化量子线路 (Ansatz)

qml.Rot(theta[0], theta[1], theta[2], wires=0)

测量 Pauli-Z 的期望值, 范围为 [-1, 1]

return qml.expval(qml.PauliZ(0))

4. 定义损失函数 (MSE)

def loss(theta):

对每个样本分别调用量子电路, 得到预测值

preds = [(circuit(x, theta) + 1) / 2 for x in X] # 映射到 [0, 1]

preds = np.array(preds)

均方误差

return np.mean((preds - Y) ** 2)

5. 初始化参数和优化器

np.random.seed(42)

theta = np.random.randn(3) # 随机初始化 3 个参数

opt = qml.GradientDescentOptimizer(stepsize=0.3)

训练轮数

```
num_epochs = 50

# 用于记录每一轮的损失值

loss_history = []

# 6. 训练循环

for epoch in range(num_epochs):

    theta = opt.step(loss, theta) # 更新参数

    current_loss = loss(theta) # 当前损失

    loss_history.append(current_loss) # 记录损失


    if epoch % 10 == 0:

        print(f"Epoch {epoch:2d}: loss = {current_loss:.4f}")


        print("\n训练完成, 最终参数 theta =", theta)


# 7. 查看最终预测效果

preds = [(circuit(x, theta) + 1) / 2 for x in X]

print("最终预测值 (接近 0 或 1 越好) :", preds)


# 8. 绘制训练损失曲线

plt.figure(figsize=(6,4))

plt.plot(range(num_epochs), loss_history, marker="o")
```

```
plt.xlabel("Epoch")

plt.ylabel("Loss (MSE)")

plt.title("Training Loss Curve of Variational Quantum Classifier")

plt.grid(True, alpha=0.3)

plt.tight_layout()

plt.show()
```

2-2

为下一次内容，此次仅做了大致了解，具体实验内容在下次实验报告中给出


五、实验结果分析

2-1结果输出如下：

```
Epoch 0: loss = 0.4163
Epoch 10: loss = 0.4113
Epoch 20: loss = 0.3887
Epoch 30: loss = 0.3240
Epoch 40: loss = 0.2799
```

```
训练完成，最终参数 theta = [0.54944422 1.18588607 0.64768854]
最终预测值（接近 0 或 1 越好）：[tensor([0.66264018], requires_grad=True), tensor([0.39779756], requires_grad=True)]
```

可视化此结果如下：



训练结果解释

从输出可以看出，损失值随着训练轮次逐渐下降：

- 初始损失为 **0.4163**
- 到第 40 轮损失下降至 **0.2799**

损失整体呈下降趋势，说明变分量子分类器成功通过参数更新学习了数据分布。

最终获得的模型参数为：

$$\theta = [0.5494, 1.1859, 0.6477]$$

模型在训练完成后的预测结果为：

- 对应真实标签 0 的输入，预测概率约为 **0.663**
- 对应真实标签 1 的输入，预测概率约为 **0.398**

由于示例数据极为简化且模型只有单比特与少量参数，预测值未完全逼近 0 或 1，但仍体现出一定的区分能力。

六、实验总结

通过本次实验，我对量子机器学习的基本流程有了初步认识。从调研工具链到搭建变分量子分类器，我了解了如何将经典数据嵌入量子态，如何构建带参数的量子线路，以及如何利用经典优化器训练量子模型。

在实现 VQC 的过程中，我观察到损失值随着训练逐渐下降，说明模型能够学习到简单的分类规律。虽然本次任务的数据规模很小、模型也比较基础，但通过实验，我理解了量子机器学习的核心思想——量子电路负责表达，经典优化负责训练，两者结合形成完整的学习系统。

总体来说，这次实验帮助我熟悉了 PennyLane 的基本使用方法，加深了我对量子-经典混合模型的理解，为后续开展更复杂的量子机器学习任务打下了基础。